


DataRush



1. Contexto y Situación del Reto

1.1. Índice de Vulnerabilidad Sociosanitaria por ZCTA

En los Estados Unidos, el acceso a los servicios médicos no explica por sí solo la salud de una comunidad. Las décadas de investigación en salud pública han demostrado que factores como el nivel de pobreza, la estructura del hogar, el acceso a transporte, el nivel educativo o el hacinamiento, lo que se conoce como Determinantes Sociales de la Salud (DSOHS), explican una porción sustancial de las desigualdades en resultados de salud entre comunidades. Dos códigos postales pueden encontrarse geográficamente cerca pero tener realidades radicalmente distintas en esperanza de vida, prevalencia de enfermedades crónicas o acceso a cuidados preventivos.

El problema es que, tradicionalmente estos dos tipos de información, el contexto social de una comunidad y sus resultados sanitarios, se han analizado por separado. Las agencias de salud pública, los planificadores urbanos y las organizaciones comunitarias suelen tener acceso a una de estas dos fuentes de información, pero rara vez tienen acceso a ambas de una manera sistemática y útil para tomar decisiones a nivel local.

1.2. El Nivel ZCTA

Trabajar a nivel de ZCTA (ZIP Code Tabulation Area), una aproximación geográfica a los códigos postales definida por el Census Bureau, es importante porque representa la unidad geográfica más pequeña y manejable en la que se pueden encontrar datos consistentes tanto sobre el contexto social, a través del ACS, como sobre resultados de salud, mediante PLACES/BRFSS, para todo el país. A diferencia de trabajar a nivel de condado o estado, donde las desigualdades dentro de cada territorio pueden perderse al resumirse en promedios, el nivel ZCTA permite identificar zonas específicas de vulnerabilidad dentro de una misma ciudad o región, justo en los lugares donde viven las comunidades y donde pueden implementarse intervenciones. Por efectos prácticos, un ZCTA se puede considerar análogo a un AGEB para el INEGI en México.

Sin embargo, trabajar con este nivel de detalle también implica un reto importante: la incertidumbre estadística. Con más de 32,000 ZCTAs en el país, muchas de estas áreas tienen poblaciones relativamente pequeñas o extremadamente grandes, lo que puede generar márgenes de error (MOE) e intervalos de confianza más amplios en las estimaciones dado que solo se sondea a una muestra de los residentes totales en la región. Ignorar esta incertidumbre puede llevar a interpretar como vulnerabilidad real lo que en realidad podría ser ruido estadístico y, como consecuencia, dirigir recursos hacia las zonas equivocadas.

1.3. Los datos disponibles y su naturaleza

Para abordar esto, se cuenta con tres fuentes de datos públicas del CDC (Centers for Disease Control and Prevention) y del Census Bureau, cada una con una estructura y propósito diferente:

- El dataset SDOH (ACS 2017–2021) aporta la parte social del análisis. Contiene nueve indicadores de determinantes sociales de la salud, como el porcentaje de hogares monoparentales, pobreza, desempleo, hacinamiento y falta de vehículo, obtenidos a partir de la Encuesta de la Comunidad Estadounidense. La información se presenta en formato largo. Se analiza en valores porcentuales de cuánto % de la población en dicho ZCTA cabe en la pregunta realizada.

- El dataset PLACES (release 2020) aporta la parte relacionada con la salud. Contiene 27 indicadores sobre resultados de salud y comportamientos de riesgo, como diabetes, obesidad, tabaquismo, salud mental y acceso a chequeos preventivos. Estos indicadores se estiman mediante modelos de área pequeña a partir de la encuesta BRFSS.
- Los archivos de referencia geográfica del Census, principalmente los Gazetteer Files y el cruce ZCTA-Condado y Estado, permiten conectar los datos con su ubicación geográfica. Las bases de SDOH y PLACES no incluyen directamente el nombre del estado o condado al que pertenece cada ZCTA, sino únicamente coordenadas y códigos numéricos.

1.4. La brecha que el reto busca cerrar

Actualmente, una persona interesada en identificar comunidades prioritarias tendría que descargar estas fuentes por separado, entender sus diferentes formatos, resolver la falta de referencias geográficas, limpiar datos que vienen en estructuras poco prácticas, como poblaciones almacenadas como texto o intervalos de confianza, y finalmente definir algún criterio para determinar qué zonas deberían recibir mayor atención. Todo esto sin contar con una herramienta que permita explorar los resultados de manera visual e interactiva.

Este reto busca cerrar precisamente esa brecha. La propuesta consiste en construir una solución estratégica mediante código que se encargue de la limpieza, integración y modelado para consolidar estas fuentes dispersas en una estructura analítica. A partir de ella, se busca desarrollar un análisis geográfico (con parte visual/gráficas) que permita a analistas y tomadores de decisiones en salud pública, sin necesidad de escribir código, identificar visualmente las comunidades donde coinciden una alta vulnerabilidad social y peores resultados de salud. Además, la herramienta permitirá entender qué factores están contribuyendo a la vulnerabilidad de cada comunidad y facilitará la decisión de dónde dirigir recursos limitados para generar el mayor impacto posible.

El objetivo no es únicamente realizar un ejercicio técnico de limpieza y unión de tablas, sino desarrollar una herramienta que pueda ser útil para la toma de decisiones. El resultado esperado es un índice compuesto de vulnerabilidad que sea estadísticamente sólido, tomando en cuenta la incertidumbre MOE; geográficamente navegable, permitiendo explorar los resultados a nivel de ZCTA y estado, pero sobre todo accionable. Es decir, que la herramienta no solo muestre dónde existe un problema, sino también qué dimensión específica, social o de salud, está contribuyendo más a la situación de cada comunidad. También se espera un pitch en video de máximo 5 minutos.

2. Glosario de Variables

2.1. Dataset SDOH

Columna	Tipo	Descripción
Year	str	Año o periodo que cubre el dato (ej. 2017-2021), correspondiente al ACS 5-year estimate.
LocationName	str	Código ZCTA (ZIP Code Tabulation Area) que identifica la ubicación geográfica.
DataSource	str	Fuente de los datos, en este caso la American Community Survey (ACS).
Category	str	Categoría temática general a la que pertenece la medida (ej. Social Context).
Measure	str	Nombre completo del indicador SDOH reportado (ej. Single-parent households).
Data_Value_Unit	str	Unidad de medida del valor reportado (ej. %).
Data_Value_Type	str	Tipo de valor estadístico reportado (ej. Percentage, Crude prevalence).
Data_Value	float64	Valor numérico estimado del indicador para ese ZCTA.
MOE	object	Margen de error (Margin of Error) de la estimación ACS, asociado al Data_Value.
TotalPopulation	str	Población total del ZCTA, usada como denominador o contexto poblacional.
LocationID	str	Identificador único del ZCTA, equivalente numérico de LocationName.
CategoryID	str	Código numérico/identificador de la categoría (equivalente a Category).
MeasureID	str	Código numérico/identificador único de la medida (equivalente a Measure).
DataValueTypeID	str	Código identificador del tipo de valor reportado (equivalente a Data_Value_Type).
Short_Question_Text	str	Versión corta o etiqueta abreviada del nombre de la medida.
Geolocation	str	Coordenadas geográficas (latitud, longitud) del centroide del ZCTA.

Cuadro 1: Glosario de columnas – Base SDOH (ACS 2017-2021)

2.2. Dataset PLACES

Columna	Tipo	Descripción
ZCTA5	str	Código ZCTA (ZIP Code Tabulation Area) de 5 dígitos que identifica la ubicación geográfica.
ACCESS2_CrudePrev	float64	Prevalencia cruda de adultos de 18-64 años sin seguro médico.
ACCESS2_Crude95CI	str	Intervalo de confianza al 95 % de ACCESS2_CrudePrev.
ARTHRITIS_CrudePrev	float64	Prevalencia cruda de artritis diagnosticada en adultos.
ARTHRITIS_Crude95CI	str	Intervalo de confianza al 95 % de ARTHRITIS_CrudePrev.
BINGE_CrudePrev	float64	Prevalencia cruda de consumo excesivo de alcohol (binge drinking) en adultos.
BINGE_Crude95CI	str	Intervalo de confianza al 95 % de BINGE_CrudePrev.
BPHIGH_CrudePrev	float64	Prevalencia cruda de hipertensión arterial diagnosticada en adultos.
BPHIGH_Crude95CI	str	Intervalo de confianza al 95 % de BPHIGH_CrudePrev.
BPMED_CrudePrev	float64	Prevalencia cruda de adultos hipertensos que toman medicación para la presión arterial.
BPMED_Crude95CI	str	Intervalo de confianza al 95 % de BPMED_CrudePrev.
CANCER_CrudePrev	float64	Prevalencia cruda de cáncer (excluyendo cáncer de piel) diagnosticado en adultos.
CANCER_Crude95CI	str	Intervalo de confianza al 95 % de CANCER_CrudePrev.
CASTHMA_CrudePrev	float64	Prevalencia cruda de asma actual en adultos.
CASTHMA_Crude95CI	str	Intervalo de confianza al 95 % de CASTHMA_CrudePrev.
CERVICAL_CrudePrev	float64	Prevalencia cruda de mujeres con tamizaje de cáncer cervical según lo recomendado.
CERVICAL_Crude95CI	str	Intervalo de confianza al 95 % de CERVICAL_CrudePrev.
CHD_CrudePrev	float64	Prevalencia cruda de enfermedad coronaria (coronary heart disease) en adultos.
CHD_Crude95CI	str	Intervalo de confianza al 95 % de CHD_CrudePrev.
CHECKUP_CrudePrev	float64	Prevalencia cruda de adultos con chequeo médico de rutina en el último año.
CHECKUP_Crude95CI	str	Intervalo de confianza al 95 % de CHECKUP_CrudePrev.

Cuadro 2: Glosario de columnas – Base PLACES (Parte 1 de 3)

Columna	Tipo	Descripción
CHOLSCREEN_CrudePrev	float64	Prevalencia cruda de adultos con tamizaje de colesterol reciente.
CHOLSCREEN_Crude95CI	str	Intervalo de confianza al 95 % de CHOLSCREEN_CrudePrev.
COLON_SCREEN_CrudePrev	float64	Prevalencia cruda de adultos con tamizaje de cáncer colorrectal según lo recomendado.
COLON_SCREEN_Crude95CI	str	Intervalo de confianza al 95 % de COLON_SCREEN_CrudePrev.
COPD_CrudePrev	float64	Prevalencia cruda de enfermedad pulmonar obstructiva crónica (EPOC) en adultos.
COPD_Crude95CI	str	Intervalo de confianza al 95 % de COPD_CrudePrev.
COREM_CrudePrev	float64	Prevalencia cruda de servicios clínicos preventivos corecibidos en hombres mayores de 65 años.
COREM_Crude95CI	str	Intervalo de confianza al 95 % de COREM_CrudePrev.
COREW_CrudePrev	float64	Prevalencia cruda de servicios clínicos preventivos corecibidos en mujeres mayores de 65 años.
COREW_Crude95CI	str	Intervalo de confianza al 95 % de COREW_CrudePrev.
CSMOKING_CrudePrev	float64	Prevalencia cruda de tabaquismo actual en adultos.
CSMOKING_Crude95CI	str	Intervalo de confianza al 95 % de CSMOKING_CrudePrev.
DENTAL_CrudePrev	float64	Prevalencia cruda de adultos que visitaron al dentista en el último año.
DENTAL_Crude95CI	str	Intervalo de confianza al 95 % de DENTAL_CrudePrev.
DIABETES_CrudePrev	float64	Prevalencia cruda de diabetes diagnosticada en adultos.
DIABETES_Crude95CI	str	Intervalo de confianza al 95 % de DIABETES_CrudePrev.
HIGHCHOL_CrudePrev	float64	Prevalencia cruda de colesterol alto diagnosticado en adultos con tamizaje reciente.
HIGHCHOL_Crude95CI	str	Intervalo de confianza al 95 % de HIGHCHOL_CrudePrev.
KIDNEY_CrudePrev	float64	Prevalencia cruda de enfermedad renal crónica diagnosticada en adultos.
KIDNEY_Crude95CI	str	Intervalo de confianza al 95 % de KIDNEY_CrudePrev.
LPA_CrudePrev	float64	Prevalencia cruda de inactividad física durante el tiempo libre en adultos.
LPA_Crude95CI	str	Intervalo de confianza al 95 % de LPA_CrudePrev.

Cuadro 3: Glosario de columnas – Base PLACES (Parte 2 de 3)

Columna	Tipo	Descripción
MAMMOUSE_CrudePrev	float64	Prevalencia cruda de mujeres con mamografía según lo recomendado.
MAMMOUSE_Crude95CI	str	Intervalo de confianza al 95 % de MAMMOUSE_CrudePrev.
MHLTH_CrudePrev	float64	Prevalencia cruda de mala salud mental frecuente (14+ días al mes) en adultos.
MHLTH_Crude95CI	str	Intervalo de confianza al 95 % de MHLTH_CrudePrev.
OBESITY_CrudePrev	float64	Prevalencia cruda de obesidad en adultos.
OBESITY_Crude95CI	str	Intervalo de confianza al 95 % de OBESITY_CrudePrev.
PHLTH_CrudePrev	float64	Prevalencia cruda de mala salud física frecuente (14+ días al mes) en adultos.
PHLTH_Crude95CI	str	Intervalo de confianza al 95 % de PHLTH_CrudePrev.
SLEEP_CrudePrev	float64	Prevalencia cruda de sueño insuficiente (menos de 7 horas) en adultos.
SLEEP_Crude95CI	str	Intervalo de confianza al 95 % de SLEEP_CrudePrev.
STROKE_CrudePrev	float64	Prevalencia cruda de accidente cerebrovascular (stroke) diagnosticado en adultos.
STROKE_Crude95CI	str	Intervalo de confianza al 95 % de STROKE_CrudePrev.
TEETHLOST_CrudePrev	float64	Prevalencia cruda de pérdida total de dientes naturales en adultos mayores de 65 años.
TEETHLOST_Crude95CI	str	Intervalo de confianza al 95 % de TEETHLOST_CrudePrev.

Cuadro 4: Glosario de columnas – Base PLACES (Parte 3 de 3)

2.3. Dataset COUNTYDAT

Columna	Tipo	Descripción
GEOID_ZCTA5_20	str	Código ZCTA (5 dígitos) que identifica la ubicación geográfica de origen.
GEOID_COUNTY_20	str	Código FIPS del condado (5 dígitos: 2 de estado + 3 de condado) asociado a ese ZCTA.
NAMELSAD_COUNTY_20	str	Nombre completo del condado (ej. "Bethel Census Area").
AREALAND_PART	int64	Área de tierra (en metros cuadrados) de la intersección entre el ZCTA y el condado. Usada para determinar el condado dominante cuando un ZCTA cruza varios condados.

Cuadro 5: Glosario de columnas – Crosswalk ZCTA-Condado (COUNTYDAT-f)

2.4. Dataset STATESDAT

Columna	Tipo	Descripción
STATE	str	Código FIPS del estado (2 dígitos, ej. 01 para Alabama).
STUSAB	str	Abreviatura postal del estado (2 letras, ej. AL).
STATE_NAME	str	Nombre completo del estado o territorio (ej. Alabama).
STATENS	int64	Código ANSI del estado (identificador estándar interno del Census Bureau).

Cuadro 6: Glosario de columnas – Referencia de Estados (STATESDAT-f)

3. Entregable

De este DataRush se espera:

- Video pitch con duración máxima de 5 minutos
- Dashboard como propuesta final del reto
- Liga de repositorio en Github: carpetas completas del proyecto

SUBMIT HERE: <https://forms.cloud.microsoft/r/FT2Pj9ZfiK>

4. Rúbrica

Rubro	Esperable
Pitch — 35 %	Que el equipo comunique el problema con claridad desde el inicio: quién se beneficia y con qué decisión concreta. La narrativa debe seguir forma de storytelling con datos e incluir al menos un hallazgo real en estos. Se valora buen manejo de la información, claridad con el punto/mensaje y un cierre conciso. Límite de pitch en video de 5 minutos.
Dashboard final (demo en vivo) — 35 %	Que se vea profesional y funcione sin errores en vivo. El mapa debe comunicar el problema de un vistazo, sin necesidad de explicación. Debe mostrar la información de ZCTAs evitando el uso de tablas crudas. Considere la incertidumbre MOE de los datos.
Impacto y accionabilidad — 15 %	Se busca que el equipo tenga un caso de uso concreto y creíble, no una idea vaga o abierta a interpretación. El dashboard debe mostrar no solo dónde está el problema, sino qué lo causa, para sugerir una acción distinta en cada caso. Se valora que el equipo tenga claro cuál sería el siguiente paso del proyecto.
Checklist técnico (SQL/datos) — 15 %	Revisión rápida. Se busca evidencia de la lógica con tablas transaccionales, pureza de datos trabajados, entendimiento del proceso detrás del dashboard.